

PRD：千问「意图记忆与可选择继承」

从“能办事”到“持续懂用户”的可信个人 AI 助手

1. 文档信息

字段	内容
产品名称	千问「意图记忆与可选择继承」
文档类型	PRD / 产品需求文档 / 面试作品集
版本	v2.0
日期	2026-06-10
阶段一范围	千问对话记忆、项目空间记忆、可选择继承、透明治理
阶段二方向	在用户逐项授权后，以阿里生态行为摘要增强意图识别
产品定位	在千问已有生态办事能力之上，构建可解释、可管理、可选择继承的可信意图记忆层

2. 一页产品判断

2.1 已有能力：千问已经能够连接真实服务

2026 年 1 月 15 日，阿里巴巴正式宣布千问 App 接入淘宝、淘宝闪购、支付宝、飞猪和高德等核心生态服务，并开放点外卖、购物、支付、旅行规划与预订等能力。千问正在从“回答问题的模型入口”转向“能够协调服务并完成任务的 AI 助手”。

这意味着，“千问是否应该结合阿里生态”已经不是待验证的产品假设。阿里的公开产品动作已经证明：**模型能力与生态服务结合，是千问面向个人 AI 助手演进的明确方向。**

2.2 当前缺口：能完成一次任务，不等于长期理解用户

生态调用解决的是“这次如何把事情办完”，但个人助手还需要解决三个连续性问题：

- 目标不连续**：用户上周制定的备考计划、长期预算或写作要求，下一次任务中仍可能需要重新说明。
- 意图不沉淀**：一次次对话和任务执行包含偏好与阶段目标，但尚未形成用户可查看、可修正的长期理解。
- 继承不可控**：历史偏好有时能提高效率，有时会干扰客观评估、风险判断或一次性敏感咨询。

因此，千问下一阶段的差异化不只是连接更多服务，而是让服务调用前后的信息形成可控闭环：

理解用户意图 -> 选择性继承相关记忆 -> 调用生态服务完成任务 -> 接收用户反馈 -> 更新对用户的理解

2.3 产品机会：在模型层与生态执行层之间增加可信意图记忆层

本方案不是简单增加“记住更多”的功能，而是建立一套用户可理解、可干预的意图记忆机制：

- 将分散的表达转化为结构化意图，而不是保存聊天流水。
- 判断什么值得长期记、什么只能停留在当前上下文。
- 允许用户决定本次任务继承哪些历史信息。
- 先通过低敏感的对话与项目记忆建立信任，再引入授权生态行为摘要。

3. 产品目标与边界

3.1 用户目标

1. 减少在长期任务中重复说明目标、约束和输出偏好的成本。
2. 清楚知道干问记住了什么、为什么记住、何时会使用。
3. 能够确认、修正、暂停和删除记忆，并查看记忆的调用情况。
4. 在客观评估或敏感任务中，能够选择只继承稳定偏好或完全不继承。

3.2 业务目标

1. 补齐干问从“服务调度入口”向“可信个人 AI 助手”演进所需的持续理解能力。
2. 提升学习、项目协作、内容创作等长期任务的复用率和完成效率。
3. 为后续生态 Agent 提供经过用户授权与校准的意图输入，降低错误执行风险。
4. 建立跨场景个性化能力的信任基础，而不是依赖黑箱画像提升短期点击或交易。

3.3 核心原则

1. **先信任，后扩源**：先做好对话和项目空间记忆，再引入生态行为摘要。
2. **记意图，不存流水**：长期记忆保存必要摘要，不汇集完整聊天、订单、轨迹或账单流水。
3. **调用授权不等于记忆授权**：用户允许干问调用淘宝下单，不代表允许将淘宝历史行为用于长期记忆。
4. **相关才继承**：不同场景按最小必要原则召回，不建立默认全局生效的统一画像。
5. **用户拥有最终解释权**：用户主动修正的信息优先于模型推断。

3.4 非目标

1. 阶段一不读取淘宝订单、高德轨迹、支付宝账单等生态行为数据。
2. 不在阶段一打通所有阿里生态产品或建立集团级用户数据池。
3. 不做医疗诊断、金融授信、未成年人画像等高风险推断。
4. 不将意图记忆直接用于广告投放；商业推荐如需使用，必须另行授权。
5. 不承诺记住所有对话内容，即时上下文默认不进入长期记忆。

4. 分阶段产品路线

4.1 阶段一：可信记忆基础层（本期 MVP）

目标：验证用户是否愿意让千问形成长期理解，以及透明、修正、删除和选择继承能否建立信任。

允许使用的记忆来源：

来源	进入方式	示例
千问普通对话	用户明确表达或模型生成候选记忆	“接下来三个月准备产品经理面试”
千问项目空间	从项目目标、资料 and 用户要求中提炼	“该项目输出默认使用中文产品文档格式”
用户主动强调	用户使用“记住”“以后都按这个”等表达	“记住我不希望简历使用夸张措辞”

阶段一不使用生态行为信号。即使千问已经能够调用淘宝、飞猪、高德等服务，也不默认读取这些服务中的历史行为用于记忆。

4.2 阶段二：授权生态意图增强

只有当阶段一达到以下门槛后，才进入生态行为摘要试点：

- 记忆确认率达到 70% 以上。
- 记忆召回相关率达到 80% 以上。
- 删除与暂停链路通过安全验收。
- 隐私投诉率未触发停止扩量红线。

候选数据范围：

生态场景	仅允许进入的摘要	不允许直接进入记忆层的内容
淘宝 / 淘宝闪购	品类倾向、预算区间、稳定复购倾向	完整订单、收货地址、单次敏感商品
高德 / 飞猪	用户确认的出行偏好、行程类型	连续轨迹、常驻地址推断、同行关系
夸克 / 学习场景	学习主题、资料类型、阶段进度	原始搜索历史、完整文件内容
支付宝	用户主动选择的预算或办事场景摘要	完整账单、资产、信用与关系推断

阶段二必须针对“数据来源、使用目的、适用场景、保存期限”重新授权。服务调用授权与行为数据用于记忆的授权分别管理、分别撤回。

5. 目标用户与核心场景

5.1 目标用户

用户	特征	主要痛点
长期学习型用户	备考、转行或持续学习，计划和资料分散	每次都要重述目标、进度与薄弱项
项目协作型用户	使用千问处理持续数周的研究、文档或创作项目	项目规则和决策难以跨会话延续
内容评审型用户	先与 AI 共创，再要求客观评价作品	历史共创立场可能影响评估可信度
生活规划型用户	已使用千问完成消费、出行等任务	希望建议逐渐贴合自己，但担心被过度画像

5.2 阶段一场景 A：学习计划持续调整

用户在普通对话中表示“未来三个月准备产品经理面试”，并在项目空间上传岗位要求和个人经历。千问生成一条“产品经理求职准备”的阶段需求记忆，设置三个月有效期。

当用户一周后询问“今天学什么”时，千问可以继承目标与项目进度生成计划，同时询问近期变化。用户无需重新解释完整背景。

关键点：阶段目标必须设置有效期，过期后需要重新确认，不能永久固化用户状态。

5.3 阶段一场景 B：项目空间规则延续

用户在一个作品集项目中持续要求“结论先行、不要使用夸张表述、所有事实标注来源”。千问识别这是项目空间内反复出现且可验证的输出偏好，生成项目级候选记忆。

用户确认后，该记忆默认仅在当前项目中继承，不影响其他聊天。

关键点：项目记忆与全局记忆分开管理，避免局部规则污染所有任务。

5.4 阶段一场景 C：独立评估

用户与千问多轮共创一份简历后，提出“客观评价一下这份简历”。千问提示可切换到“不继承”模式：不参考历史共创立场和阶段目标，只基于简历文本、岗位要求和统一评价标准输出结论。

关键点：可信助手不仅要知道何时使用记忆，也要知道何时不使用。

5.5 阶段二场景 D：健康消费意图增强

用户曾主动确认“近期希望控制夜间高热量饮食”。在另行授权淘宝闪购行为摘要后，系统发现夜间高热量品类频率持续变化，但不会直接下结论。

当用户询问“今晚吃什么”时，千问可以轻提示：“你之前确认过控制夜间高热量饮食的目标，今晚是否继续按这个目标推荐？”


关键点：生态信号用于验证和更新用户已知目标，不应仅凭消费行为推断健康状态。

6. 产品方案概述

6.1 核心能力

- 1. **候选记忆判断**：判断一条信息是否值得进入长期记忆。
- 2. **意图记忆卡片**：将目标、偏好和约束转化为可读、可管理的结构化记忆。
- 3. **千问对我的理解**：集中展示来源、置信度、范围、有效期和调用记录。
- 4. **三级选择性继承**：完整继承、仅继承稳定偏好、不继承。
- 5. **动态更新与晋级**：根据时间、用户反馈、异常偏差和多信号一致性调整记忆。
- 6. **回答级来源说明**：让用户知道本次回答受哪些记忆影响。

6.2 产品价值链



6.3 记忆与生态执行的关系

层级	解决的问题	示例
模型理解层	用户当前在说什么	理解“安排一下这周复习”
可信意图记忆层	哪些历史目标值得在本次任务中使用	继承三个月备考目标和当前进度
生态执行层	如何完成真实世界任务	调用飞猪、高德或淘宝闪购完成任务

意图记忆层不是替代生态调用，而是为调用提供经过用户校准的持续意图，并在执行后接收反馈。

7. 功能需求

7.1 F1 记忆总开关与分层授权（P0）

阶段一授权项：

维度	选项
记忆来源	普通对话、项目空间、用户主动记忆
生效范围	全局、指定场景、指定项目
使用方式	允许生成候选、允许当前任务召回、允许写入新记忆

阶段二新增独立授权项：

维度	选项
生态来源	淘宝、淘宝闪购、高德、飞猪、夸克、支付宝等逐项开关
数据形式	仅行为摘要，不传入完整原始流水
使用目的	更新已有目标、生成候选偏好、辅助当前建议

维度	选项
保存期限	单次、7 天、30 天或用户自定义

规则：

- 1. 阶段一默认仅开启用户主动要求记住的内容；自动候选记忆需用户主动开启。
- 2. 项目空间记忆默认仅在对应项目内生效。
- 3. 阶段二每个生态来源必须单独授权，且不能与服务调用授权合并勾选。
- 4. 关闭读取权限后不得新增相关记忆；撤回已生成记忆需另行选择暂停或删除。
- 5. 授权文案必须说明“使用什么、为了什么、在哪些场景生效、保留多久”。

7.2 F2 候选记忆价值判断（P0）

系统从四个维度判断信息是否值得进入长期记忆：

维度	判断问题	处理方式
高频性	是否在多个时间点重复出现	重复越多，候选权重越高
场景相关性	是否能明显改善未来同类任务	仅绑定相关场景或项目
敏感程度	是否涉及健康、财务、关系等敏感信息	默认待确认或禁止生成
可验证性	是否来自用户明确表达或多个独立信号	可验证性越高，置信度越高

准入规则：

- 1. 用户明确说“请记住”时，可直接生成用户明确记忆。
- 2. 普通表达只有在未来复用价值明确时才生成候选卡片。
- 3. 即时情绪、单次需求、临时地点等默认只进入当前上下文。
- 4. 单次行为不能直接形成稳定偏好。
- 5. 敏感推断不得静默生效，必须由用户确认。

7.3 F3 记忆类型与意图卡片（P0）

记忆类型

类型	定义	示例	默认策略
用户明确记忆	用户主动要求长期记住的事实或约束	不在简历中使用夸张措辞	直接写入，可随时编辑
稳定行为偏好	跨时间重复且未来可复用的习惯	项目文档偏好结论先行	达到阈值后待确认
阶段性需求	有开始与结束周期的目标	三个月内准备产品经理面试	必须设置有效期
敏感推断	涉及健康、财务、家庭等推断	可能希望控制饮食支出	默认待确认，不主动生效

意图卡片字段

字段	说明	示例
memory_id	记忆唯一 ID	mem_001
memory_type	记忆类型	阶段性需求
scene	适用场景	求职准备
project_scope	是否限定项目	产品作品集项目
summary	用户可读摘要	未来三个月准备产品经理面试
source_summary	来源摘要	来自两次对话与当前项目目标
evidence_count	独立证据数量	2
confidence	置信度	高 / 中 / 低
inheritance_level	允许继承层级	完整继承时使用
refresh_cycle	更新周期	每周 / 每月 / 到期复核
expires_at	有效期	2026-09-10
status	状态	待确认 / 已确认 / 已暂停 / 已删除

7.4 F4 记忆更新、异常触发与晋级（P0）

更新节奏：

记忆层级	更新策略
即时上下文	仅在当前会话或任务中生效，不进入长期记忆
阶段性需求	按任务进度更新，到期必须复核
稳定行为偏好	按周聚合信号，避免被单次变化覆盖
深度画像类总结	最多按月复核，不直接展示为人格标签

异常触发：

- 1. 当前表达与已有记忆显著冲突时，优先询问，不沿用旧记忆。
- 2. 用户连续两次标记“不相关”时，自动降低召回权重并提示是否暂停。
- 3. 阶段目标到期或长时间未使用时，进入待复核状态。

记忆晋级规则：

- 1. 单一信号源发生变化，只调整置信度，不改变记忆层级。
- 2. 多个独立信号在不同时间持续一致，才可从候选偏好晋级为稳定偏好。
- 3. 用户主动校准拥有最高优先级，可以直接修改摘要、范围和有效期。
- 4. 敏感推断不能通过自动晋级变为直接生效状态。

7.5 F5 “干问对我的理解”透明面板（P0）

入口：

- 1. 干问设置页：个性化与记忆。
- 2. 项目空间：项目记忆。
- 3. 回答底部来源说明：查看本次使用的记忆。
- 4. 新记忆提醒：查看并确认候选卡片。

页面结构：

区域	内容
总开关	是否允许生成和使用长期记忆
来源管理	对话、项目空间及阶段二生态来源开关
范围筛选	全局、场景、项目、敏感待确认
记忆卡片	摘要、类型、来源、置信度、证据数量、有效期
操作	确认、修正、暂停、删除、调整范围、查看调用记录
说明	关闭、暂停、删除之间的区别与生效时间

7.6 F6 三级可选择继承（P0）

用户在任务发起前或回答过程中，可以切换本次任务的继承范围：

模式	继承范围	典型任务
完整继承	继承相关目标、稳定偏好和项目上下文	学习计划、持续项目、个性化建议
仅继承稳定偏好	不继承阶段目标、敏感推断和历史共创立场	通用写作、陌生领域咨询
不继承	不读取长期记忆，也不将本次内容写入记忆	客观评估、敏感咨询、一次性任务

规则：

- 1. 系统只能推荐模式，不能替用户永久切换设置。
- 2. 默认只召回当前任务相关的最小记忆集合。
- 3. 用户说“客观评价”“重新判断”“不要参考之前内容”时，轻提示切换为不继承。
- 4. 用户在任务中切换模式后，应立即说明哪些历史信息已停止生效。

7.7 F7 回答级来源说明与反馈（P1）

当记忆实质影响回答或生态服务调用时，回答底部展示：

本次使用了 2 条记忆：产品经理求职目标、当前项目输出偏好。查看或调整

用户可以执行：

操作	系统结果
本次相关	提高该记忆在当前任务类型中的召回权重
本次不相关	降低当前任务类型中的召回权重
内容有误	进入修正流程，不继续沿用错误摘要
本次不再使用	从当前上下文移除，不改变长期状态

7.8 F8 独立评估任务模板（P0）

独立评估不是单独的记忆体系，而是“不继承”模式的预设任务模板。

触发场景：

- 客观评价、打分、找问题。
- 简历、方案、作品评审。
- 风险判断或是否值得购买。
- 用户明确要求重新判断。

开启后：

1. 不继承历史共创立场、阶段目标和个性化结论。
2. 允许读取用户在当前任务中主动提供的材料和评价标准。
3. 回答底部展示“本次为独立评估，未使用长期记忆”。

8. 安全、隐私与合规

8.1 数据边界

1. 阶段一仅处理干问内部的对话和项目空间信息。
2. 阶段二只接收生态产品输出的必要行为摘要，不在记忆层汇集完整原始流水。
3. 服务调用、当前任务临时读取、生成长期记忆是三种不同权限，分别授权。
4. 用户删除记忆后，该记忆立即停止召回，并在规定 SLA 内完成存储删除。
5. 所有记忆生成、修改、调用和删除保留可审计记录。

8.2 风险与处理策略

风险	典型表现	处理策略
被监视感	干问突然提及用户未主动表达的行为	阶段一不读生态行为；阶段二逐项授权并说明来源
错误固化	单次表达被长期当作稳定偏好	四维价值判断、证据数量、有效期和异常复核
跨场景污染	求职项目规则影响生活咨询	场景和项目范围隔离，最小相关召回
共创偏见	AI 因参与创作而给出偏袒评价	独立评估模板默认建议不继承

风险	典型表现	处理策略
敏感推断冒犯	根据消费推断健康或财务状态	默认待确认，使用询问式表达，禁止自动晋级
授权混淆	用户以为下单授权等于数据被长期记住	服务调用授权与记忆授权拆分展示
删除不彻底	页面删除后仍影响回答	立即停止召回、异步物理删除、审计验证

9. 技术可行性与成本

9.1 逻辑链路

- 对话或项目空间事件进入规则预过滤。
- 小模型判断是否具有长期复用价值，并完成场景与敏感分类。
- 大模型仅对高价值候选生成用户可读摘要。
- 安全策略判断直接写入、待确认或禁止生成。
- 召回层根据当前任务、继承模式、范围、置信度和有效期选择记忆。
- 回答或服务调用后收集反馈，更新权重与状态。
- 阶段二生态系统只输出授权范围内的行为摘要，不向记忆层开放原始数据库。

9.2 成本控制

成本	控制方式
意图提取调用	规则过滤 + 小模型分类 + 高价值候选才调用大模型
召回与上下文	按任务召回最小集合，限制记忆条数和 token 预算
存储	保存结构化摘要、版本和审计记录，不复制原始数据
用户确认打扰	聚合展示低风险候选，敏感和高影响记忆即时确认
跨业务接入	阶段二先做单一场景试点，再扩展数据源

10. 指标体系与实验设计

10.1 北极星指标

可信记忆任务增益率：启用记忆后，在未显著增加错误与隐私压力的前提下，长期任务完成效率或用户采纳率相对无记忆版本的提升比例。

该指标同时要求“有效”和“可信”，不能只追求记忆调用次数。

10.2 核心指标

指标	口径	阶段一目标
候选记忆确认率	用户确认的候选卡片 / 展示的候选卡片	>= 70%

指标	口径	阶段一目标
记忆召回相关率	被标记相关的调用 / 获得反馈的调用	$\geq 80\%$
重复说明减少率	同类长期任务中重复背景字数下降比例	$\geq 20\%$
任务继续率	使用记忆后继续完成下一步的任务占比	相对基线提升 10%
错误记忆修正率	被修改或标记错误的记忆 / 已生效记忆	作为质量诊断指标
记忆关闭与删除率	关闭功能或删除记忆的用户占比	观察信任压力，不单独追求低值
隐私投诉率	记忆相关投诉 / 启用用户数	设红线，触发即停止扩量
独立评估使用率	建议开启后选择不继承的任务占比	判断用户是否理解该价值

10.3 阶段一实验

分组	能力	验证目的
A 组	仅当前对话上下文	基线
B 组	对话长期记忆	验证跨会话价值
C 组	对话记忆 + 项目空间记忆 + 三级继承	验证完整可信记忆机制

样本场景：学习计划、求职准备、持续项目、内容评审。

10.4 阶段二实验

在阶段一用户中再次随机分组：

分组	能力	验证目的
D 组	仅对话与项目记忆	阶段二基线
E 组	增加单一授权生态摘要	验证生态信号的真实增益与隐私成本

阶段二不得同时接入多个生态来源，否则无法判断增益来自哪个信号，也会放大授权压力。

11. 版本规划

阶段	时间	核心目标	交付内容	放量门槛
0. 需求验证	第 1-2 周	验证用户对记忆控制和继承模式的理解	访谈、原型、文案测试	用户能区分暂停、删除和不继承
1. 可信记忆 MVP	第 3-7 周	建立对话与项目空间记忆闭环	候选判断、意图卡片、透明面板、三级继承	功能与安全验收通过
2. 小流量实验	第 8-11 周	验证任务增益与信任指标	A/B/C 实验、埋点、审计与投诉处理	确认率 $\geq 70\%$ ，相关率 $\geq 80\%$

阶段	时间	核心目标	交付内容	放量门槛
3. 单生态试点	第 12 周后	验证授权行为摘要的增量价值	单一生态来源、独立授权、D/E 实验	增益显著且未触发隐私红线
4. 跨场景扩展	试点通过后	形成理解与执行闭环	更多场景、异常更新、跨服务协作	每个来源单独评审

12. 验收标准

12.1 功能验收

- 用户可以分别管理普通对话记忆、项目空间记忆和主动记忆。
- 系统能够生成四类意图卡片，并展示来源、证据数量、置信度、范围和有效期。
- 用户可以确认、修正、暂停、删除和查看记忆调用记录。
- 用户可以在完整继承、仅继承稳定偏好、不继承之间切换。
- 独立评估任务开启后，不读取长期记忆，并明确展示状态。
- 回答使用记忆时能够展示来源入口和本次移除操作。

12.2 数据与安全验收

- 阶段一不得接入淘宝订单、高德轨迹、支付宝账单等生态行为。
- 阶段二服务调用授权与行为记忆授权必须是两个独立开关。
- 未授权来源不得进入候选记忆生成链路。
- 单次行为不得自动晋级为稳定偏好。
- 敏感推断默认待确认，且不得通过自动晋级直接生效。
- 删除记忆后立即停止召回；关闭总开关后不再读取或写入记忆。
- 每次记忆调用均可追溯到记忆 ID、任务类型和继承模式。

12.3 体验验收

- 用户在首次使用时能理解“记忆来源、用途、范围和期限”。
- 用户能区分“关闭来源”“暂停记忆”“删除记忆”和“本次不继承”。
- 候选记忆摘要使用中性、可修改的表达，不使用人格或价值判断标签。
- 模式切换不打断普通聊天，但在高影响任务中清晰可见。
- 项目空间记忆不会在无关项目或普通聊天中被召回。

13. 关键决策与取舍

13.1 为什么不在 MVP 直接使用阿里生态行为？

千问已经具备生态服务调用能力，但“能调用”解决的是执行效率，“能否将历史行为用于长期理解”是另一项授权和信任问题。如果记忆治理尚未成熟就读取订单、轨迹或账单，用户更容易产生被监视感，错误推断的影响也更大。

因此先用用户主动表达和项目空间信息验证记忆机制，再逐步引入高价值、低敏感、可解释的行为摘要。

13.2 为什么不是普通的用户画像？

传统画像主要服务推荐和运营，用户通常看不到，也难以修改。本方案中的记忆必须面向用户展示，并允许用户改变摘要、适用范围、有效期和继承方式。

13.3 为什么需要“不继承”？

个人化不是所有任务的最优答案。评价、风险判断和敏感咨询更需要减少历史立场干扰。让用户主动关闭记忆，不是削弱产品能力，而是在提高结果可信度。

14. 参考来源

- Alibaba Group, 2026-01-15: [Alibaba's Qwen App Advances Agentic AI Strategy by Turning Core Ecosystem Services into Executable AI Capabilities](#)
- Apple App Store: [千问 - 阿里 AI 助手](#)
- OpenAI Help Center: [Memory FAQ](#)
- Claude Help Center: [Use Claude's chat search and memory to build on previous context](#)
- Google Gemini Help: [Save info and reference past chats in Gemini Apps](#)
- Qwen: [Privacy Policy](#)